

CSWin-UNet + PFESA 组会汇报讲稿

适用场景：导师/组会汇报

预计时长：约 5 分钟

对应文件：汇报.pptx

第 1 页：为什么在 CSWin-UNet 上加频率注意力

本页讲述目标

说明当前改造的出发点：医学分割中的边界细、弱、容易混入伪边界，因此希望在不破坏 CSWin-UNet 主干的基础上，对 skip feature 做频率增强。

口播稿

这一页主要介绍我为什么要在 CSWin-UNet 上加入频率注意力。

在医学图像分割任务中，目标区域的边界往往比较细，而且形态不规则。尤其是病灶边缘或者组织交界区域，模型很容易出现边界不清、局部断裂，或者把一些纹理噪声误分成伪边界的问题。

CSWin-UNet 本身是一个比较强的 Transformer-UNet 基底，它通过 CSWin Transformer Block 获取更强的上下文信息，同时保留了 U-Net 的 skip connection 结构。但是原始 CSWin-UNet 并没有专门针对频率信息或者边界信息做显式增强。

我选择 CSWin-UNet 作为基底，主要不是因为它已经解决了频率增强和伪边界抑制问题，而是因为它适合作为一个稳定且结构清晰的改造平台。第一，它保留了 U-Net 的多尺度 skip connection，x1、x2、x3 这些特征层级很明确，便于我把频率增强模块插入到不同 skip 上做消融。第二，CSWin Transformer Block 能通过横向和纵向条带注意力建模更长程的上下文信息，为后续边界判断提供更强的语义基础。第三，decoder 中的 CARAFE 上采本身也更关注内容感知的特征重组，有利于恢复空间细节。相反，如果选择一个本身已经包含复杂边界分支或频率模块的网络，后续就很难说清楚提升到底来自原模型还是我加入的模块。

所以我的设计问题是：能不能只在 skip feature 上做一个轻量改造，让传给 decoder 的特征里保留更多有用的高频边界，同时利用低频结构信息减少噪声和伪边界的干扰。基于这个思路，我引入了 PFESA 的 FFT 高频/低频解耦机制，把它接到 x1、x2、x3 三条 skip feature 上做组合消融。

过渡句

接下来我先说明这两个模块分别来自哪两篇论文，以及它们在我当前模型里各自承担什么作用。

可强调点

- 当前改造不是重新设计整个网络，而是在 CSWin-UNet 基底上做 skip feature 级别的轻量增强。
- 课题关键词是：频率增强、边界细节、伪边界抑制。
- 选择 CSWin-UNet 的理由可以概括为：强基底、skip 插入点清晰、全局上下文建模能力强，同时原模型缺少显式频率/伪边界机制，适合做课题模块验证。

第 2 页：两篇论文分别提供了什么

本页讲述目标

说明 CSWin-UNet 是主干基底，PFESA 是后加的频率注意力模块，避免把两篇论文的贡献混在一起。

口播稿

这一页主要说明我当前模型的两个来源。

左边是 CSWin-UNet 论文，它提供的是整个分割网络的基底结构。具体来说，它包括 convolutional token embedding、CSWin Transformer Block、U-shaped encoder-decoder 结构，以及 decoder 里的 CARAFE 上采样和 skip connection 融合。

右边是 PFESA 论文，它提供的是一个 parameter-free 的频率注意力模块。PFESA 的核心思想是先用 FFT 把特征分解到频域，再区分高频和低频成分。高频分支对应 edge attention，更关注边界和细节；低频分支对应 structure attention，更关注整体结构和低频形态信息。

所以我当前做的不是把 PFESA 整个网络替换进来，也不是说 PFESA 是 CSWin-UNet 原始论文里的模块。更准确地说，是保留 CSWin-UNet 作为主网络，只把 PFESA 的频率注意力思想接到 CSWin-UNet 的 skip feature 上。

过渡句

明确了模块来源之后，下面这一页就是当前模型的整体结构，以及公式上这两个模块分别对应什么。

可强调点

- CSWin-UNet：提供主干网络和 decoder 结构。
- PFESA：提供频率解耦和无参数注意力。
- 当前模型是组合迁移，不是完整替换网络。

第 3 页：整体模型架构图与公式

本页讲述目标

解释当前模型的数据流，以及右侧三个公式块分别对应 CSWin attention、PFESA 频率解耦和 PFESA 注意力计算。

口播稿

这一页是当前模型的整体结构图。

整体上，左侧仍然是 CSWin-UNet 的 encoder。输入图像先经过 convolutional token embedding，然后依次进入 Stage 1 到 Stage 4。Stage 1、Stage 2、Stage 3 的输出分别作为 x1、x2、x3 三条 skip feature。

我的改动发生在 encoder 和 decoder 之间，也就是这些 skip feature 送入 decoder concat 之前。根据不同的消融设置，x1、x2、x3 可以选择性地经过 PFESA。需要注意的是，PFESA 只作用在送入 decoder 的 skip feature 上，不改变 encoder 主干继续下采样的路径。

右侧第一个公式对应 CSWin 的 stripe self-attention。它先由输入特征计算 Q、K、V，然后通过 Softmax 计算注意力输出。这个公式说明 CSWin-UNet 基底本身是通过条带窗口的 self-attention 来建模长程依赖。

第二个公式对应 PFESA 的频率解耦。输入特征经过 FFT 后，通过 Gaussian mask 得到低频部分，同时用互补 mask 得到高频部分。这里低频更偏向整体结构，高频更偏向边界细节。

第三个公式对应 PFESA 的注意力计算。EA 主要来自高频特征，用来增强边界响应；SA 主要来自低频特征，用来强调结构信息。最后把 EA 和 SA 融合后经过 Sigmoid，再乘回原始 skip feature，得到增强后的 skip。

过渡句

为了更清楚地说明 PFESA 在 skip feature 里具体做了什么，下一页我把 PFESA 的内部流程单独展开。

可强调点

- 图中 PFESA 是后加在 skip 上的模块，不是 CSWin-UNet 原论文自带模块。
- PFESA 只改变 decoder 接收到的 skip，不改变主干 encoder。
- 公式不用逐项推导，重点讲清楚每个公式对应的模块作用。

第 4 页：PFESA 内部流程

本页讲述目标

说明 PFESA 如何从 token 到 feature map，再经过 FFT、高低频分支和注意力融合，最后回到 token 形式。

口播稿

这一页进一步展开 PFESA 的内部流程。

因为 CSWin-UNet 里的特征是 token 形式，所以在送入 PFESA 之前，需要先把 skip feature 从 $B \times L \times C$ reshape 回二维特征图，也就是 $B \times C \times H_s \times W_s$ 。

然后 PFESA 对这个二维特征图做 FFT，把它转到频域。在频域中，低频部分主要对应整体结构和形态信息，高频部分主要对应边界、纹理和局部细节。

接下来，低频分支会形成 structure attention，高频分支会形成 edge attention。两个注意力相加之后经过 Sigmoid，形成最终的 attention map。这个 attention map 再和原始 skip feature 做逐元素相乘，从而得到增强后的 skip feature。

最后，增强后的特征再 reshape 回 $B \times L \times C$ 的 token 形式，送入后续 decoder 进行 concat 和上采样。

这里还有一个重要特点：PFESA 本身是不引入额外可训练参数的。因此它相对轻量，也比较适合先作为 skip feature 的频率增强模块来做消融验证。

过渡句

在明确模型结构之后，最后一页展示的是我在 new_dataset 上做的消融实验结果。

可强调点

- 高频分支对应边界和细节增强。
- 低频分支对应结构保持，并有助于减少噪声或伪边界干扰。
- PFESA 是 parameter-free，不额外增加训练参数。

第 5 页：outputs_new 验证集结果

本页讲述目标

解释不同 skip 组合的验证集表现，给出当前阶段的主要观察：x123 综合最优，x13 边界指标最优，x1/x3 单独使用不稳定。

口播稿

这一页是基于 `outputs_new` 的验证集 best epoch 结果。需要先说明一下，这里的结果来自清洗后的 new_dataset，并且是验证集结果，还不是最终 test 结果，所以不能直接作为最终泛化结论。

从 Dice 指标看，x123 是当前综合表现最好的配置。它的 Val Dice 是 0.885479，相比 baseline 的 0.884466，有一个小幅提升，提升值大约是 0.001。IoU 和 HD95 也有一定改善。这说明同时在 x1、x2、x3 三条 skip feature 上加入 PFESA，整体上比只加单条 skip 更稳定一些。

如果单独看边界指标，x13 的 Boundary IoU 是最高的，为 0.340406，高于 baseline 的 0.338314。这说明浅层 x1 的细节信息和深层 x3 的语义信息结合后，可能对边界区域有一定帮助。

但是也可以看到，x1 和 x3 单独加入 PFESA 时反而低于 baseline。这个现象也比较重要，说明频率增强不是简单地加在哪里都有效。尤其是 x1 这种浅层特征，虽然边界细节多，但噪声和伪边界也更多，单独增强高频信息可能会带来干扰。

所以当前阶段我更倾向于把 x123 作为综合表现较好的配置，把 x13 作为边界指标上的一个有价值观察。后续还需要在 test split 上进一步验证，才能判断它们是否具有稳定泛化能力。

过渡句

以上就是目前基于 CSWin-UNet 和 PFESA skip 增强得到的结构设计和初步消融结果。

可强调点

- x123 综合最优，但提升幅度较小，不能夸大。
- x13 边界指标最优，可以作为后续边界增强方向的线索。
- 当前是验证集 best epoch 结果，不是最终 test 结论。
- x1/x3 单独使用不稳定，说明伪边界和浅层噪声需要进一步控制。

总结收尾

如果最后需要补一句总结，可以这样说：

总体来说，我当前的工作是在 CSWin-UNet 这个基底上，引入 PFESA 的频率解耦注意力，对 skip feature 做轻量增强。实验上，x123 在验证集综合指标上最好，x13 在边界指标上最好，但目前结果仍然是验证集观察，后续还需要补充 test 结果，并进一步考虑显式边界分支或者伪边界抑制机制。